

Milestone 2

- **Autorzy:** Mateusz Świątek, Maciej Mężyk, Patryk Skowron
 - **Zbiór:** PCR Lab Data
 - **Źródło:** [Zenodo #11617408](#)
 - **Notebook:** [notebooks/02_m2_endpoint_clustering.ipynb](#)
-

1. Cel i zakres

Celem Milestone 2 jest analiza endpointów (adresów serwisów) w logu zdarzeń:

1. Zmapować endpointy na zdarzenia — zbudować macierz rozkładów i określić czy mapowanie jest 1:1 czy wiele-do-wielu.
2. Sprawdzić czy niektóre endpointy łączą się w jedno zdarzenie (np. ten sam serwis na dwóch domenach).
3. Normalizacja → redukcja wymiarowości (PCA/UMAP) → klasteryzacja → walidacja klastrów względem 8 docelowych zdarzeń.

Pipeline: **endpointy** → **normalizacja** → **PCA/UMAP** → **klasteryzacja hierarchiczna** → **walidacja**.

2. Dane i przygotowanie

- Dane wejściowe: `data/processed/pcr_events_biz.parquet` i `data/processed/pcr_cases.parquet`.
- Do mapowania endpointów bierzemy wyłącznie zdarzenia typu `start` (bez dublowania z `complete`).

Metryka	Wartość
Zdarzenia <code>start</code> z endpointem	51 209
Surowe endpointy (unikalne URL)	63
Typy zdarzeń	28

Normalizacja per-instance CPEE

49 z 63 surowych endpointów to adresy instancji silnika CPEE (`cpee.org/flow/engine/{id}/properties/state/`), różniące się jedynie identyfikatorem instancji. Normalizujemy je do jednego typu. Wynik: **15 logicznych typów endpointów** × 28 zdarzeń.

8 docelowych zdarzeń

Na potrzeby walidacji wyróżniamy 8 zdarzeń zdefiniowanych w zadaniu:

Zdarzenie
Callback timeout
Export result
Export to EMS
Match patient data
Receive sample state
Send notification
Wait for plate validation
timeout

3. Mapowanie endpoint → zdarzenie

3.1 Metoda

1. Budujemy macierz `endpoint × zdarzenie` (liczność wystąpień `start`).
2. Dla każdego endpointa wyznaczamy dominujące zdarzenie i jego udział procentowy.
3. Klasyfikujemy mapowanie:
4. **1:1** — endpoint występuje tylko w jednym typie zdarzenia.
5. **Mostly** — dominujący udział $\geq 95\%$, ale endpoint pojawia się w kilku zdarzeniach.
6. **Multi** — brak dominacji, endpoint wspólny dla wielu zdarzeń.

3.2 Wyniki

Typ mapowania	Liczba endpointów
1:1	5
Mostly	1
Multi	9

Mapowanie jest **wiele-do-wielu**: jeden endpoint (np. `*/backend/corr`) obsługuje do 12 zdarzeń, a jedno zdarzenie (np. `timeout`) korzysta z 3 endpointów.

Endpointy 1:1:

Endpoint	Zdarzenie
<code>cpee.org/services/powernap.php</code>	Sleep
<code>greschner.azurewebsites.net/.../notifyall</code>	Send notification
<code>greschner.azurewebsites.net/.../pcheck</code>	Check for unfinished Plates
<code>mygreschner.com/.../notifyall</code>	Send notification
<code>mygreschner.com/.../pcheck</code>	Check for unfinished Plates

Endpoint mostly (1):

Endpoint	Zdarzeń	Dominujące zdarzenie	Udział
<code>cpee.org/flow/start/url</code>	3	Spawn per sample flow	49%

Pozostałe zdarzenia: Finish wellplate watcher, Spawn Single Wellplate.

Endpointy multi (9) — najistotniejsze:

Endpoint	Zdarzeń	Dominujące zdarzenie	Udział
<code>greschner.azurewebsites.net/backend/corr</code>	12	Match patient data	32%
<code>mygreschner.com//backend/corr</code>	4	Match patient data	46%
<code>*/services/timeout*</code> (3 endpointy)	2	timeout	73–88%
<code>GET:cpee.org/.../message/receive</code>	3	Wait for plate validation	47%
<code>POST:cpee.org/.../message/send</code>	3	Notify per wellplate subprocess	35%

3.3 Odwrotne mapowanie: zdarzenie → endpointy


Sprawdzamy czy niektóre endpointy łączą się w jedno zdarzenie.

Zdarzenie	Endpointów	Wniosek
timeout	3	Ten sam serwis timeout na 2 domenach + 2 wersjach
Callback timeout	3	j.w.
Match patient data	2	<code>*/backend/corr</code> na 2 domenach
Receive sample state	2	j.w.
Export result	2	j.w.
Export to EMS	2	j.w.
Send notification	2	<code>*/notifyall</code> na 2 domenach
Check for unfinished Plates	2	<code>*/pcheck</code> na 2 domenach
Finish wellplate	2	<code>*/backend/corr</code> na 2 domenach
New Wellplate	2	j.w.

Zdarzenie	Endpointów	Wniosek
Wait for plate validation	1	Jedyny endpoint
Import EPS File	1	Jedyny endpoint
Validate plate	1	Jedyny endpoint
Remaining (15 zdarzeń)	1	Po jednym endpointzie

Wniosek: Większość zdarzeń jest obsługiwana przez ten sam serwis zduplikowany na dwóch domenach (`mygreschner.com` i `greschner.azurewebsites.net`). To nie są odrębne serwisy — to ta sama logika na dwóch hostach.

3.4 Heatmapa macierzy endpoint x zdarzenie




Heatmapa potwierdza widoczny podział: endpointy `*/backend/corr` obsługują szerokie spektrum zdarzeń, natomiast serwisy timeout, notyfikacji i sprawdzania płytek są wyspecjalizowane.

4. Redukcja wymiarowości

Normalizacja: `log1p` + `StandardScaler` na macierzy 15×28.

4.1 PCA



Kolory odpowiadają typowi mapowania: zielony = 1:1, pomarańczowy = mostly, czerwony = multi.


Metryka	Wartość
Wariancja PC1	34.9%
Wariancja PC2	11.5%
Suma (2 komponenty)	46.4%

`greschner.azurewebsites.net/backend/corr` jest wyraźnym outlierem na PC1 — obsługuje 12 zdarzeń, co daje mu unikalny profil.

`GET:cpee.org/.../message/receive` wyróżnia się na PC2 jako najczęściej wywoływany korelator (12 957 wywołań).

Endpointy 1:1 (zielone) grupują się blisko siebie — mają proste, jednozdarzeniowe profile. Endpointy multi (czerwone) rozpraszają się szeroko, odzwierciedlając ich zróżnicowane spektra zdarzeń.

4.2 UMAP




UMAP daje lepszą separację niż PCA. Widoczne grupy:

- **Serwisy timeout** (3 endpointy): obsługują `timeout` i `Callback timeout`.
 - **Endpointy `*/backend/corr`**: obie domeny blisko siebie — podobne profile zdarzeń.
 - **Serwisy platformy CPEE**: `flow/start`, `engine/{id}`, `powernap`, korelatory.
 - **Serwisy notyfikacji i sprawdzania płytek**: `*/notifyall`, `*/pcheck`.
-

5. Klasteryzacja i walidacja

5.1 Dendrogram



Klasteryzacja hierarchiczna (Ward). Dendrogram potwierdza:

- **Najwcześniejsze łączenia** (odległość < 2): pary tego samego serwisu na dwóch domenach — `*/notifyall` (0.7), `*/pcheck` (0.7), `*/timeout` + `*/timeout2` (1.3).
- **Środkowy poziom** (4–8): grupy funkcjonalne — timeout serwisy, korelatory CPEE, backend corr.
- **Najpóźniejsze łączenia** (>10): `greschner.../backend/corr` i `cpee.org/flow/start/url` dołączają ostatnie — mają unikalne profile zdarzeń.

5.2 Walidacja klastrów

Testujemy trzy poziomy cięcia dendrogramu: k=3, k=5, k=8.

k	Silhouette	Opis
3	0.250	Trzy duże grupy — słaba separacja
5	0.273	Najlepsza wartość — wyspecjalizowane endpointy wydzielone
8	0.230	Zbyt drobne podziały przy n=15

Niskie wartości silhouette (0.23–0.27) wynikają z małego n=15. Struktura jest jednak czytelna w dendrogramie.

Klastry przy k=5 (najlepszy silhouette):

Klaster	Endpointy	Zdarzenia (wybrane)
1	11	timeout, Callback timeout, Match patient data, Export result, Export to EMS, Receive sample state, Send notification, Check for unfinished Plates, Sleep i inne
2	1 (GET:cpee.org/.../receive)	Wait for plate validation, Receive finishids, Wait for finished plate
3	1 (POST:cpee.org/.../send)	Notify per wellplate subprocess, Notify plain instance, Send plate validation
4	1 (cpee.org/flow/start/url)	Spawn per sample flow, Spawn Single Wellplate, Finish wellplate watcher
5	1 (greschner.../backend/corr)	Match patient data, Export result, Export to EMS, Receive sample state, Import EPS File, Validate plate i inne (12 zdarzeń)

Klastry 2–5 to singletony — endpointy o unikalnych profilach. Klaster 1 gromadzi 11 endpointów o prostszych lub nakładających się profilach.

Klastry przy k=8 (granulacja per serwis):

Klaster	Endpointy	Dominujące zdarzenia
1	3 (timeout×3)	timeout, Callback timeout
2	6 (notifyall, pcheck, powernap, mygreschner/corr)	Send notification, Check for unfinished Plates, Sleep, Export result, Match patient data
3	1 (engine/{id})	Abandon spawned sample, Stopping spawned sample
4	1 (mygreschner.com//backend/corr)	

Klaster	Endpointy	Dominujące zdarzenia
		Match patient data, Export result, Export to EMS, Receive sample state
5	1 (GET:cpee.org/.../receive)	Wait for plate validation, Receive finishids
6	1 (POST:cpee.org/.../send)	Notify per wellplate subprocess, Notify plain instance
7	1 (cpee.org/flow/start/url)	Spawn per sample flow, Spawn Single Wellplate
8	1 (greschner.../backend/corr)	12 zdarzeń (Match patient data, Import EPS File, Validate plate, ...)


Klastry 4 i 8 to oba `*/backend/corr` — obsługują wiele tych samych zdarzeń, ale nie klastrują się razem, ponieważ `greschner.../backend/corr` obsługuje dodatkowo 8 zdarzeń, których `mygreschner.com//backend/corr` nie ma.

6. Wykrywanie outlierów (sample)

Cechy per case: `duration_min`, `n_events`, `hour`, `dayofweek`.
 Normalizacja `StandardScaler`.

Algorytm	Outlierów	%
Isolation Forest (contamination=5%)	302	4.9%
LOF (k=20, contamination=5%)	309	5.0%
DBSCAN (eps=1.5, min_samples=10)	29	0.5%

DBSCAN wydzieliła 3 klastry, tylko 29 outlierów — dane są skupione. IF i LOF wykrywają po ~300 próbek.



	duration_min	n_events	hour	dayofweek
Normalne	173.5	10	16	2
Outlier	420.8	12	14	3

Outlierzy to próbki o $\sim 2.5\times$ dłuższym czasie i więcej zdarzeń — prawdopodobnie utknęły na noc w kolejce do płytki.

7. Wnioski

- Mapowanie jest wiele-do-wielu.** 9 z 15 endpointów obsługuje wiele zdarzeń; jednocześnie wiele zdarzeń korzysta z więcej niż jednego endpointa. Nie istnieje proste mapowanie 1:1 między endpointami a zdarzeniami.
- Duplikacja domen.** Serwisy `mygreschner.com` i `greschner.azurewebsites.net` to te same usługi na dwóch hostach. Dendrogram łączy je na najniższym poziomie (odległość < 2). Po logicznej konsolidacji domen mamy efektywnie 4–5 unikalnych serwisów, nie 8.
- Centralny komponent:** `*/backend/corr`. Ten endpoint obsługuje 12 zdarzeń i jest outlierem zarówno w PCA, jak i w klasteryzacji. To hub systemu CPEE łączący procesy różnych typów.
- Endpointy = serwisy wielokrotnego użytku.** Klasteryzacja grupuje endpointy wg funkcji serwisowej (timeout, notyfikacje, korelacja), a nie wg procesu. Endpointy nie są dedykowanymi modułami per zdarzenie — to współdzielone mikroserwisy.
- Ograniczenia analizy.** $n=15$ punktów to minimum dla PCA/UMAP/ klasteryzacji. Silhouette (max 0.273) jest niski, ale dendrogram i UMAP

dają czytelną strukturę. Przy większej liczbie endpointów (np. w systemie produkcyjnym z setkami serwisów) pipeline byłby bardziej informatywny.

6. **Outlierzy.** IF i LOF wskazują ~5% próbek jako anomalie — głównie te o czasie >400 min (utknęły na noc). DBSCAN: 3 klastry, 29 outlierów. Anomalie wynikają z rytmu pracy laboratorium, nie z błędów procesowych.