

Milestone 3

- **Autorzy:** Mateusz Świątek, Maciej Mężyk, Patryk Skowron
- **Zbiór:** PCR Lab Data
- **Źródło:** [Zenodo #11617408](#)
- **Notebook:** [notebooks/03_m3_process_discovery.ipynb](#)

1. Cel i zakres

Celem Milestone 3 jest odkrycie i analiza modelu procesu na podstawie logu zdarzeń PCR Lab:

1. Wygenerowanie DFG (Directly-Follows Graph) w wersji częstościowej i wydajnościowej.
2. Porównanie czterech algorytmów odkrywania modelu: Alpha Miner, Inductive Miner (IM), IMf, Heuristic Miner.
3. Analiza zgodności modeli z logiem (conformance checking).
4. Stworzenie modelu BPMN i propozycje usprawnień.
5. Odkrycie reguł decyzyjnych (drzewa decyzyjne).
6. Analiza zasobów (endpointy jako proxy mikrousług).
7. Identyfikacja wąskich gardeł i symulacja Monte Carlo.
8. Interaktywny dashboard HTML.

Pipeline: EventLog → DFG → odkrywanie modelu (×4) → conformance → BPMN → reguły → zasoby → symulacja → dashboard.

2. Dane i przygotowanie

- Dane wejściowe: `data/processed/pcr_events_biz.parquet` i `data/processed/pcr_cases.parquet`.
- Do odkrywania modelu używamy wyłącznie zdarzeń `complete`, czyli jednego punktu w czasie na aktywność, zgodnie ze standardem process mining.
- Do analizy zasobów używamy zdarzeń `start` (moment wywołania endpointu).

Metryka	Wartość
Przypadki (process_type = sample)	6 166
Zdarzenia <code>complete</code>	32 356
Zdarzenia <code>start</code>	51 209
Unikalne aktywności	8
Warianty procesu	47


Konwersja do pm4py EventLog

DataFrame przetworzono przez `pm4py.format_dataframe()` z mapowaniem: - `case_id = instance_uuid`, `activity_key = activity`, `timestamp_key = timestamp`

Wynikowy EventLog: 6 162 traces (4 przypadki bez zdarzeń `complete` pominięto).

3. DFG: Directly-Follows Graph

3.1 Frequency DFG




Graf ma 28 łuków. Najczęstsze bezpośrednie następstwa:

Aktywność źródłowa	Aktywność docelowa	Liczba
Wait for plate validation	Receive sample state	5 921
Match patient data	Wait for plate validation	5 444
Receive sample state	Callback timeout	4 990
Callback timeout	timeout	4 812
timeout	Send notification	1 229
Match patient data	timeout	498

Dominuje ścieżka główna: Match patient data → Wait for plate validation → Receive sample state → Callback timeout → timeout (65% przypadków). Łuk Match patient data → timeout

(n=498) to alternatywna ścieżka pomijająca walidację płytki, prawdopodobnie próbki nieprzypisane do żadnej płytki lub przetwarzane w trybie awaryjnym.

3.2 Performance DFG



Heatmapa pokazuje czas complete(A) → complete(B) w minutach, czyli czas od zakończenia aktywności A do zakończenia aktywności B w tym samym przypadku.

Aktywności timeout, Match patient data i Wait for plate validation startują równocześnie (CPEE odpala je równolegle w ramach jednego przypadku). W przykładowym przypadku wszystkie trzy zdarzenia start mają timestamp 14:17:41, Match patient data kończy się po ~6 sekundach, a Wait for plate validation po ~165 minutach. Wartość 162 min na krawędzi Match patient data → Wait for plate validation nie jest więc czasem oczekiwania między aktywnościami, tylko service time aktywności Wait for plate validation (czas procesowania PCR), który zaczął się równolegle.


Przejście	Mediana [min]	n	Interpretacja
Match patient data → timeout (alt.)	420	498	Service time timeout na ścieżce alternatywnej
Receive sample state → timeout	232	292	Ścieżka alternatywna overnight
Match patient data → Wait for plate validation	162	5 444	≈ service time WFPV (165 min), PCR processing
Wait for plate validation → Receive sample state	~0	5 921	Sekwencyjne, natychmiastowe

Wniosek: bottleneck to fizyczny czas procesowania PCR (~165 min), a nie czas oczekiwania między aktywnościami. System już korzysta z równoległości, bo wszystkie

kroki inicjalizacji startują jednocześnie. Jedyną drogą optymalizacji jest zmniejszenie rozmiaru partii płytek (mniejsza partia = krótszy czas do zakończenia).

4. Odkrywanie modelu procesu

4.1 Alpha Miner (kontrprzykład)




Właściwość	Wartość
Miejsca	15
Przejścia	8
Łuki	41

Alpha Miner generuje uproszczoną sieć z 8 widzialnymi przejściami odpowiadającymi 8 aktywnościom. Model jest zbyt prosty: nie radzi sobie z pętlami (timeout powtarza się w procesie) i nie modeluje prawidłowo skipów ani alternatywnych ścieżek. Wynik conformance (fitness=0.51) potwierdza, że model nie opisuje rzeczywistego zachowania systemu.

Alpha Miner zakłada acykliczny, skończony język, dlatego nie nadaje się do danych rzeczywistych. Pętle i zachowanie niedeterministyczne powodują brakujące miejsca w sieci Petriego (sieć nie jest sound), co uniemożliwia prawidłowy replay śladów.


4.2 Inductive Miner (IM)



Właściwość	Wartość
Miejsca	21
Przejścia	28
Łuki	64

IM rekurencyjnie dzieli log na podlogi i buduje model gwarancyjnie sound (każdy ślad logu da się odtworzyć na modelu). Wynikowa sieć ma 28 przejść, z czego wiele to przejścia τ (ciche), modelujące pomijalne kroki. Fitness = 1.000 (idealna), ale bardzo niska precision (0.41) oznacza, że model jest zbyt ogólny: pozwala na wiele zachowań, których nie ma w logu.



4.3 Inductive Miner Infrequent (IMf, noise_threshold = 0.2)



Właściwość	Wartość
Miejsca	12
Przejścia	11
Łuki	26

IMf najpierw filtruje rzadkie zachowania (poniżej 20% częstości), a następnie stosuje Inductive Miner na oczyszczonym logu. Wynikowy model jest znacznie prostszy: 11 przejść wobec 28 w IM. Fitness spada do 0.96 (4.1% śladów nie przechodzi), ale precision rośnie do 0.70, a F1 = 0.806 to drugi wynik po Heuristic Minerze.

4.4 Heuristic Miner (dep_threshold = 0.5)



Właściwość	Wartość
Miejsca	20


Właściwość	Wartość
Przejścia	30
Łuki	69

Heuristic Miner buduje model na podstawie DFG z progami zależności
(dependency_threshold = 0.5 : łuk A→B uwzględniany, gdy $(A \rightarrow B - B \rightarrow A) / (A \rightarrow B + B \rightarrow A + 1) \geq 0.5$). Daje najwyższy F1 = 0.967 (fitness=0.975, precision=0.959). Model wiernie odwzorowuje obserwowane zachowanie i nie jest przy tym zbyt restrykcyjny.

5. Analiza zgodności (Conformance Checking)

Conformance checking przeprowadzono metodą token-based replay (TBR): dla każdego śladu logu symulujemy wykonanie na sieci Petriego i zliczamy brakujące oraz nadmiarowe tokeny.

5.1 Tabela porównawcza



Algorytm	Fitness	% pasujących tras	Precision	F1	Miejsca	Przejścia
Alpha Miner	0.506	0.8%	1.000	0.672	15	8
Inductive Miner (IM)	1.000	100.0%	0.409	0.581	21	28
IMf (noise=0.2)	0.960	88.9%	0.695	0.806	12	11
Heuristic Miner	0.975	73.1%	0.959	0.967	20	30

5.2 Interpretacja

Alpha Miner: fitness 0.506 oznacza, że połowa śladów wymaga "dostrzelenia" brakujących tokenów podczas replay. Precision wynosi 1.0, bo model jest tak restrykcyjny, że nie pozwala niemal na nic. W praktyce model jest niepoprawny (niespójny z danymi) i nie nadaje się do użycia produkcyjnego.

Inductive Miner (IM): idealna fitness (100% tras przechodzi), ale precision 0.41. Model jest zbyt liberalny, dopuszcza sekwencje aktywności, których nigdy nie obserwowano w


1. Optymalizacja Wait for plate validation (~162 min mediany na ścieżce głównej). To główny bottleneck na ścieżce przetwarzania 88% przypadków. Płytki (wellplate) jest wypełniana próbkami, a walidacja następuje po zebraniu pełnej partii. Redukcja rozmiaru partii lub zwiększenie częstości uruchamiania walidacji mogłaby skrócić ten czas o 30-50%.
2. Równoległe wykonanie eksportów (AND-split). Export result, Export to EMS i Send notification są w danych wykonywane sekwencyjnie, choć logicznie mogą być

równoległe (brak zależności danych między nimi). AND-split po `Receive sample state` skróciłby czas zakończenia przypadku o ~20-30 min dla 35% próbek.

3. SLA dla przypadków przekraczających 8 godzin. P95 czasu trwania wynosi ~19 godzin. Przypadki ze ścieżką alternatywną (`Match patient data` → `timeout`, mediana 420 min) są prawdopodobnie wstrzymane przez brak dostępnej płytki lub błąd systemu. Alert lub mechanizm priorytetu po przekroczeniu 8 godzin zmniejszyłby ich liczbę.
4. Optymalizacja konfiguracji `timeout CPEE`. Aktywność `timeout` to mechanizm kolejkowania silnika CPEE, który pojawia się na wszystkich ścieżkach jako ostatnia aktywność. Optymalizacja interwałów `timeoutu` może skrócić oczekiwanie w kolejce bez zmiany logiki procesowej.
5. Dedykowana ścieżka dla próbek pilnych. Dane nie zawierają priorytetu próbki. Wprowadzenie atrybutu `priority` pozwoliłoby kierować próbki pilne na ścieżkę pomijającą `Wait for plate validation` (np. na mniejszą płytkę testową lub do natychmiastowego procesowania).

7. Odkrycie reguł decyzyjnych

7.1 Predykcja wyniku PCR




Cechy: `duration_min`, `n_events`, `hour`, `dayofweek`. Cel: `POSITIVE` / `NEGATIVE`.

Metryka	Wartość
Baseline (klasa wiodąca)	0.528
CV Accuracy (5-fold)	0.526 ± 0.009

CV accuracy jest niemal równe baseline (52.8%), więc wyniku PCR nie da się przewidzieć z cech procesowych. Potwierdza to obserwacje z Milestone 1: czas trwania, liczba zdarzeń, pora dnia i dzień tygodnia są niezależne od wyniku badania. Wynik PCR zależy od biologii próbki, a nie od charakterystyki procesu laboratoryjnego.

7.2 Predykcja obecności eksportu



Cechy: `duration_min`, `n_events`, `hour`, `dayofweek`, `pcr_binary`. Cel: czy przypadek zawiera aktywność eksportu (Export result / Export to EMS).

Target	Prevalence	Baseline	CV Accuracy	Top cecha
is_main_variant	65.0%	0.650	~0.65	duration_min
has_export	35.0%	0.650	0.999	n_events
has_notification	~20.0%	0.800	~0.98	n_events

`n_events` niemal idealnie determinuje, czy przypadek ma aktywność eksportu (CV=0.999). Reguła jest prosta i deterministyczna:


```
if n_events >= 7:
    → case zawiera eksport (Export result / Export to EMS)
else:
    → case bez eksportu (główna ścieżka, 5 zdarzeń)
```

Liczba zdarzeń wynika bezpośrednio ze struktury wariantu: główna ścieżka ma 5 aktywności (complete), a ścieżki z eksportem 6-8. Nie jest to reguła „decyzyjna” w sensie biznesowym, tylko tautologia wynikająca z definicji wariantu. Właściwe pytanie brzmi: co decyduje o skierowaniu próbki na ścieżkę z eksportem? Dane procesowe nie zawierają tej informacji, a sama decyzja prawdopodobnie pochodzi z zewnętrznego systemu LIS lub protokołu laboratorium.

8. Analiza zasobów: endpointy jako proxy usług

Log PCR Lab nie zawiera identyfikatorów zasobów (pracowników ani maszyn). Jako reprezentacji mikrousług CPEE używamy endpointów URL: każdy endpoint odpowiada konkretnej usłudze laboratoryjnej obsługiwanej przez silnik procesowy. Analiza pokazuje obciążenie poszczególnych serwisów i wzorce przekazywania pracy między nimi.

8.1 Obciążenie endpointów




Po normalizacji (collapse per-instance IDs silnika CPEE) uzyskano 8 unikalnych logicznych endpointów:

Endpoint (skrót)	Wywołania	Dominujące aktywności
mygreschner.com//backend/corr	~23 000	Match patient data, Receive sample state, Export result, ... (12 aktywności)
*/services/timeout	~15 000	timeout, Callback timeout
GET:cpee.org/.../receive	~7 000	Wait for plate validation
*/notifyall	~2 500	Send notification
*/pcheck	~2 000	Check for unfinished Plates
POST:cpee.org/.../send	~1 500	Notify per wellplate subprocess
cpee.org/flow/start/url	~400	Spawn per sample flow
cpee.org/engine/{id}/...	~200	Abandon/Stop spawned sample

*/backend/corr dominuje: obsługuje ponad 40% wszystkich wywołań i 12 różnych aktywności. To centralna usługa korelacji CPEE, hub systemu.

8.2 Macierz handover of work




Macierz przedstawia liczbę przekazania pracy między endpointami (ile razy endpoint B bezpośrednio następuje po endpointcie A w ramach tego samego przypadku). Kluczowe obserwacje:

- `*/backend/corr` → `*/timeout`: największy przepływ. Po korelacji przypadek przechodzi do timeoutu (oczekiwanie na kolejny krok).
- `*/timeout` → `*/backend/corr`: powrót z timeoutu do korelacji. Pętla `timeout` ↔ `backend/corr` to rdzeń procesu.
- `GET:cpee.org/.../receive` → `*/backend/corr`: po odebraniu stanu płytki (Wait for plate validation → Receive sample state) następuje powrót do korelacji.
- `*/notifyall` i `*/pcheck` to endpointy liściowe z małą liczbą przekazania.

8.3 Sieć współpracy endpointów


Siec współpracy endpointow (przekazania > 30)



Sieć potwierdza centralną rolę `*/backend/corr` : łączy się z niemal wszystkimi innymi endpointami. Serwisy timeout tworzą wyraźną pętlę z korelatorem. Serwisy notyfikacji i sprawdzania płytek (`*/notifyall` , `*/pcheck`) to peryferyjne węzły z małą liczbą połączeń.

9. Analiza wąskich gardeł i symulacja Monte Carlo

9.1 Wąskie gardła




Przejście	Mediana [min]	n	Ocena
Match patient data → timeout (alt.)	420	498	Krytyczne
Receive sample state → timeout (alt.)	232	292	Krytyczne
Match patient data → Wait for plate validation	162	5 444	Krytyczne (główna ścieżka)
Send notification → Export to EMS	285	55	Wysokie
Export to EMS → timeout	194	39	Wysokie

Najistotniejszy bottleneck to service time `Wait for plate validation` (~165 min, n=5 444). Jak pokazała analiza struktury procesu (sekcja 3.2), `Match patient data` i `Wait for plate validation` startują jednocześnie, więc wartość 162 min na krawędzi DFG to service time PCR, a nie czas oczekiwania w kolejce. To ograniczenie fizyczne (batchowy charakter procesu PCR), możliwe do zredukowania przez zmniejszenie rozmiaru partii.

Przejścia `→ timeout (alt.)` o ekstremalnych medianach (420, 232 min) to przypadki ze ścieżki alternatywnej: próbki, które po wstępnym przetworzeniu trafiają bezpośrednio do kolejki `timeout` zamiast do `Wait for plate validation`. Prawdopodobna przyczyna to brak dostępnej płytki w momencie przetwarzania, co skutkuje oczekiwaniem overnight.

9.2 Symulacja Monte Carlo



Metodologia: 2 000 przebiegów. W każdym przebiegu losujemy wariant z rozkładu empirycznego, a dla każdego przejścia czas z rozkładu empirycznego (sampling bez zastępowania z obserwacji historycznych).

Metryka	Symulacja	Rzeczywiste
Mediana [min]	174.9	175.3
Średnia [min]	336.1	331.0
P95 [min]	1 228.4	1 148.5

Symulacja odtwarza medianę niemal idealnie (174.9 vs 175.3 min, błąd 0.2%) i dobrze przybliża średnią (336.1 vs 331.0 min). Rozkład jest prawostronnie skośny: większość przypadków kończy się w 100–300 min, ale długi ogon (overnight) przesunął średnią do ~330 min.

Symulacja nieznacznie przeszacowuje P95 (1 228 vs 1 149 min, +7%): empiryczne samplowanie czasów przejść z długim ogonem (zdarzenia overnight) generuje w 2 000 przebiegach nieco więcej ekstremów niż w rzeczywistym logu. Model dobrze odwzorowuje tendencję centralną i nadaje się do planowania przepustowości. Dla pojedynczych ekstremów jest obciążony wariancją Monte Carlo (brak ustalonego ziarna oznacza, że wartości mogą się różnić między przebiegami).

Scenariusz optymalizacyjny: redukcja czasu Match patient data → Wait for plate validation z 162 do 60 minut (przez zmniejszenie partii płytek o 60%) przesunęłaby medianę czasu trwania z 175 do ~75 minut, czyli o 57%.

10. Mini Dashboard

Dashboard HTML dostępny w pliku <results/m3/dashboard.html>.

6 interaktywnych paneli: 1. Top 15 przejść DFG (częstość) 2. Rozkład czasu trwania przypadku 3. Top 10 wariantów procesu 4. Obciążenie endpointów 5. Wąskie gardła (mediana czasu przejścia) 6. Conformance: Fitness / Precision / F1 dla 4 algorytmów

11. Interpretacja procesu i wnioski

Co model mówi o analizowanym systemie?

System PCR Lab to batchowy proces laboratoryjny zarządzany przez silnik procesowy CPEE. Każda próbka przechodzi przez standardową sekwencję kroków: identyfikacja pacjenta → oczekiwanie na kompletację płytki → odczyt wyniku PCR → opcjonalny eksport do systemów zewnętrznych → zamknięcie przypadku. System jest wysoce powtarzalny (65% przypadków na jednej ścieżce) i działa w przewidywalnym rytmie dobowym (pon.-pt., 11:00–21:00).

Najczęstsze ścieżki procesu

Wariant	Udział	Ścieżka
Główna	65.0%	Match patient data → Wait for plate validation → Receive sample state → Callback timeout → timeout
Top 2	70.9%	j.w. + eksport (Export result / Export to EMS)
Top 10	92.8%	Wszystkie powyższe + warianty kolejności eksportów

Gdzie pojawiają się opóźnienia?

1. Wait for plate validation (~162 min): oczekiwanie na skompletowanie płytki 96-studzienkowej. To ograniczenie technologiczne procesu PCR, ale redukowalne przez zmniejszenie rozmiaru wsadu.
2. Ścieżka alternatywna, czyli brak płytki: 498 przypadków z przejściem Match patient data → timeout (mediana 420 min). Próbkę bez przypisanej płytki czekają na kolejny cykl pracy laboratorium, często overnight.
3. Sekwencyjne eksporty: w 35% przypadków aktywności Export result / Export to EMS / Send notification są wykonywane sekwencyjnie, choć mogłyby być równoległe.

Rekomendacje biznesowe

Rekomendacja	Wpływ	Trudność
Zmniejszenie rozmiaru partii płytek (96 → 48)	–50% mediany czasu na głównej ścieżce	Średnia
Równoległość eksportów (AND-split)	–20–30 min na 35% przypadków	Niska
SLA 8h + alert dla wstrzymanych próbek	Eliminacja outlierów overnight	Niska
Priorytetyzacja próbek pilnych	Skrócenie P95	Wysoka
Optymalizacja timeout CPEE	Redukcja overhead kolejkwania	Niska

Ograniczenia analizy

- Brak zasobów w logu: analizujemy endpointy zamiast pracowników czy urządzeń, więc nie można ocenić obciążenia personelu.
- Brak atrybutu priorytetu próbki: nie można odróżnić próbek rutynowych od pilnych.
- Nieznany kontekst zewnętrzny: decyzja o skierowaniu na ścieżkę z eksportem pochodzi z zewnętrznego systemu LIS, którego nie ma w logu. Drzewo decyzyjne (n_events jako determinant) ujawnia tautologię, a nie przyczynę.
- Dane z jednego okresu (kwiecień-czerwiec 2023): wzorce mogą różnić się między szczytem pandemii a normalną pracą laboratorium.