

Milestone 3

- **Autorzy:** Mateusz Świątek, Maciej Mężyk, Patryk Skowron
- **Zbiór:** PCR Lab Data
- **Źródło:** [Zenodo #11617408](#)
- **Notebook:** [notebooks/03_m3_process_discovery.ipynb](#)

1. Cel i zakres

Celem Milestone 3 jest odkrycie i analiza modelu procesu na podstawie logu zdarzeń PCR Lab:

1. Wygenerowanie DFG (Directly-Follows Graph) w wersji częstościowej i wydajnościowej.
2. Porównanie czterech algorytmów odkrywania modelu: Alpha Miner, Inductive Miner (IM), IMf, Heuristic Miner.
3. Analiza zgodności modeli z logiem (conformance checking).
4. Stworzenie modelu BPMN i propozycje usprawnień.
5. Odkrycie reguł decyzyjnych (drzewa decyzyjne).
6. Analiza zasobów (endpointy jako proxy mikrousług).
7. Identyfikacja wąskich gardeł i symulacja Monte Carlo.
8. Interaktywny dashboard HTML.

Pipeline: EventLog → DFG → odkrywanie modelu (×4) → conformance → BPMN → reguły → zasoby → symulacja → dashboard.

2. Dane i przygotowanie

- Dane wejściowe: `data/processed/pcr_events_biz.parquet` i `data/processed/pcr_cases.parquet`.
- Do odkrywania modelu używamy wyłącznie zdarzeń `complete`, czyli jednego punktu w czasie na aktywność, zgodnie ze standardem process mining.
- Do analizy zasobów używamy zdarzeń `start` (moment wywołania endpointu).

Metryka	Wartość
Przypadki (process_type = sample)	6 166
Zdarzenia complete	32 356
Zdarzenia start	51 209
Unikalne aktywności	8
Warianty procesu	47


Konwersja do pm4py EventLog

DataFrame przetworzono przez `pm4py.format_dataframe()` z mapowaniem: - `case_id = instance_uuid`, `activity_key = activity`, `timestamp_key = timestamp`

Wynikowy EventLog: 6 162 traces (4 przypadki bez zdarzeń `complete` pominięto).

3. DFG: Directly-Follows Graph

3.1 Frequency DFG




Graf ma 28 łuków. Najczęstsze bezpośrednie następstwa:

Aktywność źródłowa	Aktywność docelowa	Liczba
Wait for plate validation	Receive sample state	5 921
Match patient data	Wait for plate validation	5 444
Receive sample state	Callback timeout	4 990
Callback timeout	timeout	4 812
timeout	Send notification	1 229
Match patient data	timeout	498

Dominuje ścieżka główna: Match patient data → Wait for plate validation → Receive sample state → Callback timeout → timeout (65% przypadków). Łuk Match patient data → timeout

(n=498) to alternatywna ścieżka pomijająca walidację płytki, prawdopodobnie próbki nieprzypisane do żadnej płytki lub przetwarzane w trybie awaryjnym.

3.2 Performance DFG



Heatmapa pokazuje czas complete(A) → complete(B) w minutach, czyli czas od zakończenia aktywności A do zakończenia aktywności B w tym samym przypadku.

Aktywności timeout, Match patient data i Wait for plate validation startują równocześnie (CPEE odpala je równolegle w ramach jednego przypadku). W przykładowym przypadku wszystkie trzy zdarzenia start mają timestamp 14:17:41, Match patient data kończy się po ~6 sekundach, a Wait for plate validation po ~165 minutach. Wartość 162 min na krawędzi Match patient data → Wait for plate validation nie jest więc czasem oczekiwania między aktywnościami, tylko service time aktywności Wait for plate validation (czas procesowania PCR), który zaczął się równolegle.


Przejście	Mediana [min]	n	Interpretacja
Match patient data → timeout (alt.)	420	498	Service time timeout na ścieżce alternatywnej
Receive sample state → timeout	232	292	Ścieżka alternatywna overnight
Match patient data → Wait for plate validation	162	5 444	≈ service time WFPV (165 min), PCR processing
Wait for plate validation → Receive sample state	~0	5 921	Sekwencyjne, natychmiastowe

Wniosek: bottleneck to fizyczny czas procesowania PCR (~165 min), a nie czas oczekiwania między aktywnościami. System już korzysta z równoległości, bo wszystkie

kroki inicjalizacji startują jednocześnie. Jedyną drogą optymalizacji jest zmniejszenie rozmiaru partii płytek (mniejsza partia = krótszy czas do zakończenia).

4. Odkrywanie modelu procesu

4.1 Alpha Miner (kontrprzykład)




Właściwość	Wartość
Miejsca	15
Przejścia	8
Łuki	41

Alpha Miner generuje uproszczoną sieć z 8 widzialnymi przejściami odpowiadającymi 8 aktywnościom. Model jest zbyt prosty: nie radzi sobie z pętlami (timeout powtarza się w procesie) i nie modeluje prawidłowo skipów ani alternatywnych ścieżek. Wynik conformance (fitness=0.51) potwierdza, że model nie opisuje rzeczywistego zachowania systemu.

Alpha Miner zakłada acykliczny, skończony język, dlatego nie nadaje się do danych rzeczywistych. Pętle i zachowanie niedeterministyczne powodują brakujące miejsca w sieci Petriego (sieć nie jest sound), co uniemożliwia prawidłowy replay śladów.


4.2 Inductive Miner (IM)



Właściwość	Wartość
Miejsca	21
Przejścia	28
Łuki	64

IM rekurencyjnie dzieli log na podlogi i buduje model gwarancyjnie sound (każdy ślad logu da się odtworzyć na modelu). Wynikowa sieć ma 28 przejść, z czego wiele to przejścia τ (ciche), modelujące pomijalne kroki. Fitness = 1.000 (idealna), ale bardzo niska precision (0.41) oznacza, że model jest zbyt ogólny: pozwala na wiele zachowań, których nie ma w logu.



4.3 Inductive Miner Infrequent (IMf, noise_threshold = 0.2)



Właściwość	Wartość
Miejsca	12
Przejścia	11
Łuki	26

IMf najpierw filtruje rzadkie zachowania (poniżej 20% częstości), a następnie stosuje Inductive Miner na oczyszczonym logu. Wynikowy model jest znacznie prostszy: 11 przejść wobec 28 w IM. Fitness spada do 0.96 (4.1% śladów nie przechodzi), ale precision rośnie do 0.70, a F1 = 0.806 to drugi wynik po Heuristic Minerze.

4.4 Heuristic Miner (dep_threshold = 0.5)



Właściwość	Wartość
Miejsca	20

Właściwość	Wartość
Przejścia	30
Łuki	69


Heuristic Miner buduje model na podstawie DFG z progami zależności

(`dependency_threshold = 0.5`: łuk $A \rightarrow B$ uwzględniany, gdy $(A \rightarrow B - B \rightarrow A) / (A \rightarrow B + B \rightarrow A + 1) \geq 0.5$). Daje najwyższy $F1 = 0.967$ (fitness=0.975, precision=0.959). Model wiernie odwzorowuje obserwowane zachowanie i nie jest przy tym zbyt restrykcyjny.

5. Analiza zgodności (Conformance Checking)

Conformance checking przeprowadzono metodą token-based replay (TBR): dla każdego śladu logu symulujemy wykonanie na sieci Petriego i zliczamy brakujące oraz nadmiarowe tokeny.

5.1 Tabela porównawcza



Algorytm	Fitness	% pasujących tras	Precision	F1	Miejsca	Przejścia
Alpha Miner	0.506	0.8%	1.000	0.672	15	8
Inductive Miner (IM)	1.000	100.0%	0.409	0.581	21	28
IMf (noise=0.2)	0.960	88.9%	0.695	0.806	12	11
Heuristic Miner	0.975	73.1%	0.959	0.967	20	30

5.2 Interpretacja

Alpha Miner: fitness 0.506 oznacza, że połowa śladów wymaga "dostrzeżenia" brakujących tokenów podczas replay. Precision wynosi 1.0, bo model jest tak restrykcyjny, że nie pozwala niemal na nic. W praktyce model jest niepoprawny (niespójny z danymi) i nie nadaje się do użycia produkcyjnego.

Inductive Miner (IM): idealna fitness (100% tras przechodzi), ale precision 0.41. Model jest zbyt liberalny, dopuszcza sekwencje aktywności, których nigdy nie obserwowano w

danych. Nadaje się do weryfikacji formalnej poprawności, ale nie do opisu rzeczywistego procesu.


IMf: dobry kompromis, 88.9% tras pasuje, precision 0.70, F1 0.806. Uproszczony model (11 przejść) dobrze opisuje „normalne” zachowanie i ignoruje rzadkie warianty (<20%).

Heuristic Miner: najlepszy model dla tych danych (F1=0.967). Wiernie odwzorowuje rzeczywiste DFG i nie generalizuje nadmiernie. 73.1% śladów przechodzi token replay w pełni, a pozostałe 26.9% to ślady z nieoczekiwaną kolejnością aktywności (rare variants), które Heuristic Miner modeluje jako alternatywne ścieżki.

Do analizy tego procesu najlepiej nadaje się Heuristic Miner. Log jest stosunkowo mało zaszumiony (47 wariantów, 65% przypadków na jednej ścieżce), co czyni go dobrym kandydatem dla algorytmu opartego bezpośrednio na DFG.

6. Model BPMN i propozycje usprawnień

6.1 BPMN z Heuristic Miner (najlepszy F1)



Model BPMN wygenerowano z najlepszego modelu (Heuristic Miner, F1=0.967) przez konwersję Petri net → BPMN w pm4py. Kluczowe elementy:


Główna ścieżka (65% przypadków): Start → Match patient data → Wait for plate validation → Receive sample state → Callback timeout → timeout → End

Ścieżki z eksportem (~13% przypadków, głównie próbki POSITIVE, patrz §7.2). Po Receive sample state możliwe gałęzie: - Export result → Export to EMS → Callback timeout - Export to EMS → Export result → Callback timeout (bez EMS) - Export to EMS → Callback timeout (bez result)

Ścieżka z powiadomieniem: timeout → Send notification → (Wait for plate validation | Export to EMS | ...)

6.2 BPMN z Inductive Miner (model blokowy)

BPMN z Inductive Miner (IMf): model blokowy — AND-split (+) inicjalizacji, XOR (x) dla powiadomienia




Inductive Miner zwraca drzewo procesu, które przekłada się wprost na BPMN. Wersja z filtrem rzadkich zachowań (IMf) daje czysty model blokowy z jawnymi bramkami: AND-split (+) inicjalizacji, XOR (x) dla powiadomienia i pętla (*) na Match patient data.

Co z tego modelu wynika:

- Proces jest równoległy, nie sekwencyjny: AND-split pokazuje, że timeout, łańcuch walidacji płytki i powiadomienie startują jednocześnie po Match patient data. To niezależnie potwierdza obserwację z §3.2 i tłumaczy, dlaczego 162 min to service time PCR, a nie czas oczekiwania w kolejce.
- Jedyna sekwencja krytyczna to Wait for plate validation → Receive sample state → Callback timeout. Reszta to równoległe gałęzie poboczne, więc wąskie gardło musi leżeć w tym łańcuchu (i leży: WFPV ~165 min, §9).
- Powiadomienie to realny wybór (XOR), a nie stały krok procesu.
- Pętla (*) na Match patient data oznacza, że część próbek przechodzi ponowną identyfikację (rework).
- Eksport nie pojawia się w tym modelu: IMf odfiltrował go jako rzadki (~13%), więc model opisuje „normalny” przebieg bez eksportu, a eksport jest wyjątkiem dla próbek dodatnich (patrz §6.3).

6.3 Bramka decyzyjna eksportu (XOR)

Bramka XOR po Receive sample state: wynik PCR decyduje o gałęzi eksportu



Najważniejsza bramka rozgałęziająca to decyzja o eksporcie po Receive sample state: wynik POSITIVE kieruje próbkę do Export to EMS, ujemny ją pomija. Regułę wyprowadzamy z danych w §7.2 (86.9% gałęzi eksportu to próbki dodatnie).


Propozycje usprawnień

1. Optymalizacja Wait for plate validation (~162 min mediany na ścieżce głównej). To główny bottleneck na ścieżce przetwarzania 88% przypadków. Płytki (wellplate) jest wypełniana próbkami, a walidacja następuje po zebraniu pełnej partii. Redukcja rozmiaru partii lub zwiększenie częstotliwości uruchamiania walidacji mogłaby skrócić ten czas o 30-50%.
2. Równoległe wykonanie eksportów (AND-split). Export result, Export to EMS i Send notification są w danych wykonywane sekwencyjnie, choć logicznie mogą być równoległe (brak zależności danych między nimi). AND-split po Receive sample state skróciłby czas zakończenia przypadku o ~20-30 min dla ~13% próbek z eksportem.
3. SLA dla przypadków przekraczających 8 godzin. P95 czasu trwania wynosi ~19 godzin. Przypadki ze ścieżką alternatywną (Match patient data → timeout, mediana 420 min) są prawdopodobnie wstrzymane przez brak dostępnej płytki lub błąd systemu. Alert lub mechanizm priorytetu po przekroczeniu 8 godzin zmniejszyłby ich liczbę.
4. Optymalizacja konfiguracji timeout CPEE. Aktywność timeout to mechanizm kolejkowania silnika CPEE, który pojawia się na wszystkich ścieżkach jako ostatnia aktywność. Optymalizacja interwałów timeoutu może skrócić oczekiwanie w kolejce bez zmiany logiki procesowej.
5. Dedykowana ścieżka dla próbek pilnych. Dane nie zawierają priorytetu próbki. Wprowadzenie atrybutu priority pozwoliłoby kierować próbki pilne na ścieżkę

pomijającą Wait for plate validation (np. na mniejszą płytkę testową lub do natychmiastowego procesowania).

7. Odkrycie reguł decyzyjnych

7.1 Predykcja wyniku PCR




Cechy: duration_min, n_events, hour, dayofweek. Cel: POSITIVE / NEGATIVE.

Metryka	Wartość
Baseline (klasa wiodąca)	0.530
CV Accuracy (5-fold)	0.645 ± 0.009

Model bije baseline o ~11 pp (CV 0.645 vs 0.530), ale głównie dzięki n_events (ważność 0.75, pozostałe cechy dokładają ~25%). Cechy niezależne od wyniku, czyli czas trwania, pora dnia i dzień tygodnia, są wobec wyniku płaskie (zgodnie z Milestone 1: mediana czasu 183 min dla POSITIVE vs 172 min dla NEGATIVE). Sygnał bierze się stąd, że n_events koduje obecność eksportu, a eksport zależy od wyniku (patrz §7.2). Wniosek: wyniku PCR nie da się przewidzieć z cech niezależnych od wyniku (czas, pora, dzień), ale jest on odzwierciedlony w strukturze procesu. Proces nie przewiduje wyniku, tylko na niego reaguje, uruchamiając dla próbek dodatnich gałąź raportującą.

7.2 Predykcja obecności eksportu



Cechy: `duration_min`, `n_events`, `hour`, `dayofweek`, `pcr_binary`. Cel: czy przypadek zawiera aktywność eksportu (Export result / Export to EMS).

Target	Prevalence	Baseline	CV Accuracy	Top cecha
is_main_variant	66.9%	0.669	0.995	n_events
has_export	13.3%	0.867	0.999	n_events
has_notification	20.1%	0.799	0.980	duration_min

`n_events` przewiduje wszystkie trzy cele niemal idealnie (CV 0.98–0.999), ale to tautologia: każda dodatkowa aktywność (eksport, powiadomienie) zwiększa `n_events`, więc liczba zdarzeń z definicji koduje strukturę wariantu. To nie jest reguła biznesowa.

Co więc decyduje o gałęzi eksportu (bramka XOR)? Po usunięciu tautologicznego `n_events` widać, że eksport jest silnie powiązany z wynikiem PCR:


Kierunek zależności	Wartość
P(POSITIVE jest eksport)	86.9%
P(eksport POSITIVE)	24.7%
P(eksport NEGATIVE)	3.3%

Jeśli próbka ma eksport, jest niemal na pewno dodatnia (86.9%). Pozytywy są zgłaszane do systemu epidemiologicznego (EMS), ujemne prawie nigdy (24.7% vs 3.3%, czyli 7.5×). W drugą stronę zależność jest słabsza, bo eksportowanych jest tylko ~25% pozytywów. Wynik dodatni jest więc warunkiem niemal koniecznym eksportu, ale nie wystarczającym. O tym, które pozytywy trafiają do zgłoszenia, decyduje kryterium spoza logu (eksportowane mają wyższe ct, mediana 31 vs 25, czyli słabsze wirémie). To wyjaśnia §7.1: `n_events` koduje obecność eksportu, więc niesie częściowy sygnał o wyniku. Proces nie przewiduje wyniku, tylko na niego reaguje dodatkową gałęzią raportowania.

8. Analiza zasobów: endpointy jako proxy usług

Log PCR Lab nie zawiera identyfikatorów zasobów (pracowników ani maszyn). Jako reprezentacji mikrousług CPEE używamy endpointów URL: każdy endpoint odpowiada konkretnej usłudze laboratoryjnej obsługiwanej przez silnik procesowy. Analiza pokazuje obciążenie poszczególnych serwisów i wzorce przekazywania pracy między nimi.

8.1 Obciążenie endpointów




Po normalizacji (collapse per-instance IDs silnika CPEE) uzyskano 8 unikalnych logicznych endpointów:

Endpoint (skrót)	Wywołania	Dominujące aktywności
mygreschner.com//backend/corr	~23 000	Match patient data, Receive sample state, Export result, ... (12 aktywności)
*/services/timeout	~15 000	timeout, Callback timeout
GET:cpee.org/.../receive	~7 000	Wait for plate validation
*/notifyall	~2 500	Send notification
*/pcheck	~2 000	Check for unfinished Plates
POST:cpee.org/.../send	~1 500	Notify per wellplate subprocess
cpee.org/flow/start/url	~400	Spawn per sample flow
cpee.org/engine/{id}/...	~200	Abandon/Stop spawned sample

`*/backend/corr` dominuje: obsługuje ponad 40% wszystkich wywołań i 12 różnych aktywności. To centralna usługa korelacji CPEE, hub systemu.

8.2 Macierz handover of work




Macierz przedstawia liczbę przekazania pracy między endpointami (ile razy endpoint B bezpośrednio następuje po endpointzie A w ramach tego samego przypadku). Kluczowe obserwacje:

- `*/backend/corr` → `*/timeout`: największy przepływ. Po korelacji przypadek przechodzi do timeoutu (oczekiwanie na kolejny krok).
- `*/timeout` → `*/backend/corr`: powrót z timeoutu do korelacji. Pętla `timeout` ↔ `backend/corr` to rdzeń procesu.
- `GET:cpee.org/.../receive` → `*/backend/corr`: po odebraniu stanu płytki (Wait for plate validation → Receive sample state) następuje powrót do korelacji.
- `*/notifyall` i `*/pcheck` to endpointy liściowe z małą liczbą przekazania.

8.3 Sieć współpracy endpointów


Siec współpracy endpointow (przekazania > 30)



Siec potwierdza centralną rolę `*/backend/corr` : łączy się z niemal wszystkimi innymi endpointami. Serwisy timeout tworzą wyraźną pętlę z korelatorem. Serwisy notyfikacji i sprawdzania płytek (`*/notifyall` , `*/pcheck`) to peryferyjne węzły z małą liczbą połączeń.

9. Analiza wąskich gardeł i symulacja Monte Carlo

9.1 Wąskie gardła




Przejście	Mediana [min]	n	Ocena
Match patient data → timeout (alt.)	420	498	Krytyczne
Receive sample state → timeout (alt.)	232	292	Krytyczne
Match patient data → Wait for plate validation	162	5 444	Krytyczne (główna ścieżka)
Send notification → Export to EMS	285	55	Wysokie
Export to EMS → timeout	194	39	Wysokie

Najistotniejszy bottleneck to service time `Wait for plate validation` (~165 min, n=5 444). Jak pokazała analiza struktury procesu (sekcja 3.2), `Match patient data` i `Wait for plate validation` startują jednocześnie, więc wartość 162 min na krawędzi DFG to service time PCR, a nie czas oczekiwania w kolejce. To ograniczenie fizyczne (batchowy charakter procesu PCR), możliwe do zredukowania przez zmniejszenie rozmiaru partii.

Przejścia `→ timeout (alt.)` o ekstremalnych medianach (420, 232 min) to przypadki ze ścieżki alternatywnej: próbki, które po wstępnym przetworzeniu trafiają bezpośrednio do kolejki `timeout` zamiast do `Wait for plate validation`. Prawdopodobna przyczyna to brak dostępnej płytki w momencie przetwarzania, co skutkuje oczekiwaniem overnight.

9.2 Symulacja Monte Carlo



Metodologia: 2 000 przebiegów. W każdym przebiegu losujemy wariant z rozkładu empirycznego, a dla każdego przejścia czas z rozkładu empirycznego (sampling bez zastępowania z obserwacji historycznych).

Metryka	Symulacja	Rzeczywiste
Mediana [min]	174.9	175.3
Średnia [min]	336.1	331.0
P95 [min]	1 228.4	1 148.5

Symulacja odtwarza medianę niemal idealnie (174.9 vs 175.3 min, błąd 0.2%) i dobrze przybliża średnią (336.1 vs 331.0 min). Rozkład jest prawostronnie skośny: większość przypadków kończy się w 100–300 min, ale długi ogon (overnight) przesunął średnią do ~330 min.

Symulacja nieznacznie przeszacowuje P95 (1 228 vs 1 149 min, +7%): empiryczne samplowanie czasów przejść z długim ogonem (zdarzenia overnight) generuje w 2 000 przebiegach nieco więcej ekstremów niż w rzeczywistym logu. Model dobrze odwzorowuje tendencję centralną i nadaje się do planowania przepustowości. Dla pojedynczych ekstremów jest obciążony wariancją Monte Carlo (brak ustalonego ziarna oznacza, że wartości mogą się różnić między przebiegami).

Scenariusz optymalizacyjny: redukcja czasu Match patient data → Wait for plate validation z 162 do 60 minut (przez zmniejszenie partii płytek o 60%) przesunęłaby medianę czasu trwania z 175 do ~75 minut, czyli o 57%.

10. Mini Dashboard

Dashboard HTML dostępny w pliku <results/m3/dashboard.html>.

6 interaktywnych paneli: 1. Top 15 przejść DFG (częstość) 2. Rozkład czasu trwania przypadku 3. Top 10 wariantów procesu 4. Obciążenie endpointów 5. Wąskie gardła (mediana czasu przejścia) 6. Conformance: Fitness / Precision / F1 dla 4 algorytmów

11. Interpretacja procesu i wnioski

Porównanie z procesem odkrytym w Milestone 2 (klasteryzacja)

Proces odkryto dwukrotnie: w M3 metodą process mining ze zdarzeń `complete` (8 aktywności biznesowych), a w M2 metodą klasteryzacji niskopoziomowego payloadu zdarzeń (12 klastrów K1-K12). Oba podejścia odtwarzają ten sam rdzeń procesu (zgodność klastrów z ground truth: purity 0.93):

Aspekt	Proces ze zdarzeń (M3)	Proces z klastrów (M2)
Szkielet główny	Match → Wait for plate validation → Receive sample state → Callback timeout → timeout	K1 → K6 → K4 → K5 → K9 = timeout → Match → Wait → Receive → Callback (te same kroki)
Zakres	tylko proces <code>sample</code> : 8 aktywności, 6 166 przypadków	wszystkie typy procesu (<code>sample</code> + <code>wellplate</code> + orkiestracja): 28 aktywności, 6 339 przypadków
<i>Receive sample state</i>	jedna aktywność	rozbite na 3 klastry wg pozycji na płytce (K2/K5/K12, mediana 9/35/73)
Gałąź eksportu	modelowana jako bramka XOR	niewidoczna, bo <code>Export result</code> / <code>Export to EMS</code> mają tę samą sygnaturę argumentów (<code>pid, sampleid</code>) co <code>Match patient data</code> i zlewają się w klaster K6
Kolejność <code>timeout</code>	ostatnia (sortowanie po <code>complete</code>)	pierwsza (sortowanie po <code>start</code>), bo te aktywności startują równolegle (patrz §3.2)

Wniosek: klasteryzacja niskopoziomowa odtwarza rdzeń procesu i dodatkowo wydobywa strukturę przestrzenną (pozycja na płytce), ale nie widzi gałęzi raportujących (eksport), ponieważ różni je wyłącznie ground truth (wynik PCR) świadomie wykluczony z cech w M2. To granica metody: klastry pokazują, *jak* płynie proces, ale nie *dlaczego* się rozgałęzia. To drugie ujawnia dopiero reguła decyzyjna z §7.2 (wynik dodatni uruchamia eksport).

Co model mówi o analizowanym systemie?

System PCR Lab to batchowy proces laboratoryjny zarządzany przez silnik procesowy CPEE. Każda próbka przechodzi przez standardową sekwencję kroków: identyfikacja pacjenta → oczekiwanie na kompletację płytki → odczyt wyniku PCR → opcjonalny eksport do systemów zewnętrznych → zamknięcie przypadku. System jest wysoce powtarzalny (65% przypadków na jednej ścieżce) i działa w przewidywalnym rytmie dobowym (pon.-pt., 11:00–21:00).

Najczęstsze ścieżki procesu

Wariant	Udział	Ścieżka
Główna	65.0%	Match patient data → Wait for plate validation → Receive sample state → Callback timeout → timeout
Top 2	70.9%	j.w. + eksport (Export result / Export to EMS)
Top 10	92.8%	Wszystkie powyższe + warianty kolejności eksportów

Gdzie pojawiają się opóźnienia?

1. Wait for plate validation (~162 min): oczekiwanie na skompletowanie płytki 96-studzienkowej. To ograniczenie technologiczne procesu PCR, ale redukowalne przez zmniejszenie rozmiaru wsadu.
2. Ścieżka alternatywna, czyli brak płytki: 498 przypadków z przejściem Match patient data → timeout (mediana 420 min). Próbkę bez przypisanej płytki czekają na kolejny cykl pracy laboratorium, często overnight.
3. Sekwencyjne eksporty: w ścieżkach pobocznych (~35% przypadków: eksport ~13%, powiadomienie ~20%) aktywności Export result / Export to EMS / Send notification są wykonywane sekwencyjnie, choć mogłyby być równoległe.

Rekomendacje biznesowe

Rekomendacja	Wpływ	Trudność
Zmniejszenie rozmiaru partii płytek (96 → 48)	–50% mediany czasu na głównej ścieżce	Średnia
Równoległość eksportów (AND-split)	–20–30 min na ~13% przypadków z eksportem	Niska
SLA 8h + alert dla wstrzymanych próbek	Eliminacja outlierów overnight	Niska
Priorytetyzacja próbek pilnych	Skrócenie P95	Wysoka
Optymalizacja timeout CPEE	Redukcja overhead kolejkowania	Niska

Ograniczenia analizy

- Brak zasobów w logu: analizujemy endpointy zamiast pracowników czy urządzeń, więc nie można ocenić obciążenia personelu.
- Brak atrybutu priorytetu próbki: nie można odróżnić próbek rutynowych od pilnych.
- Zewnętrzny kontekst raportowania: gałąź eksportu jest sterowana wynikiem PCR (POSITIVE → EMS, §7.2), ale log nie tłumaczy wyjątków (3.3% próbek ujemnych również eksportowanych) ani kolejności samych eksportów. Zależy to od konfiguracji zewnętrznego systemu raportowania.
- Dane z jednego okresu (kwiecień-czerwiec 2023): wzorce mogą różnić się między szczytem pandemii a normalną pracą laboratorium.