

Milestone 3

- **Autorzy:** Mateusz Świątek, Maciej Mężyk, Patryk Skowron
 - **Zbiór:** PCR Lab Data
 - **Źródło:** [Zenodo #11617408](#)
 - **Notebook:** [notebooks/03_m3_process_discovery.ipynb](#)
-

1. Cel i zakres

Celem Milestone 3 jest odkrycie i analiza modelu procesu na podstawie logu zdarzeń PCR Lab:

1. Wygenerowanie DFG (Directly-Follows Graph) — częstościowego i wydajnościowego.
2. Porównanie czterech algorytmów odkrywania modelu: Alpha Miner, Inductive Miner (IM), IMf, Heuristic Miner.
3. Analiza zgodności modeli z logiem (conformance checking).
4. Stworzenie modelu BPMN i propozycje usprawnień.
5. Odkrycie reguł decyzyjnych (drzewa decyzyjne).
6. Analiza zasobów — endpointy jako proxy mikrousług.
7. Identyfikacja wąskich gardeł i symulacja Monte Carlo.
8. Interaktywny dashboard HTML.

Pipeline: **EventLog** → **DFG** → **odkrywanie modelu (×4)** → **conformance** → **BPMN** → **reguły** → **zasoby** → **symulacja** → **dashboard**.

2. Dane i przygotowanie

- Dane wejściowe: `data/processed/pcr_events_biz.parquet` i `data/processed/pcr_cases.parquet`.
- Do odkrywania modelu używamy **wyłącznie zdarzeń complete** — jeden punkt w czasie na aktywność, zgodnie ze standardem process mining.
- Do analizy zasobów używamy zdarzeń `start` (moment wywołania endpointu).

Metryka	Wartość
Przypadki (process_type = sample)	6 166
Zdarzenia <code>complete</code>	32 356
Zdarzenia <code>start</code>	51 209
Unikalne aktywności	8
Warianty procesu	47


Konwersja do pm4py EventLog

DataFrame przetworzono przez `pm4py.format_dataframe()` z mapowaniem: - `case_id = instance_uuid`, `activity_key = activity`, `timestamp_key = timestamp`

Wynikowy EventLog: **6 162 traces** (4 przypadki bez zdarzeń `complete` pominięte).

3. DFG — Directly-Follows Graph

3.1 Frequency DFG




Graf posiada **28 łuków**. Najczęstsze bezpośrednie następstwa:

Aktywność źródłowa	Aktywność docelowa	Liczba
Wait for plate validation	Receive sample state	5 921
Match patient data	Wait for plate validation	5 444
Receive sample state	Callback timeout	4 990
Callback timeout	timeout	4 812
timeout	Send notification	1 229
Match patient data	timeout	498

Dominuje **ścieżka główna**: Match patient data → Wait for plate validation → Receive sample state → Callback timeout → timeout (65% przypadków). Łuk Match patient data → timeout

(n=498) to alternatywna ścieżka pomijająca walidację płytki — prawdopodobnie próbki nieprzypisane do żadnej płytki lub przetwarzane w trybie awaryjnym.

3.2 Performance DFG



Heatmapa pokazuje czas **complete(A) → complete(B)** w minutach — czas od zakończenia aktywności A do zakończenia aktywności B w tym samym przypadku.


Ważna uwaga o strukturze procesu: Analiza logów ujawniła, że aktywności `timeout`, `Match patient data` i `Wait for plate validation` **startują równocześnie** (CPEE odpala je równolegle w ramach jednego przypadku). Przykładowy przypadek: wszystkie trzy aktywnościowe zdarzenia `start` mają timestamp `14:17:41`, `Match patient data` kończy się po ~6 sekundach, a `Wait for plate validation` po ~165 minutach. Oznacza to, że wartość 162 min na krawędzi `Match patient data → Wait for plate validation` to **nie jest czas oczekiwania między aktywnościami** — to service time aktywności `Wait for plate validation` (czas procesowania PCR), który zaczął się równolegle.

Przejście	Mediana [min]	n	Interpretacja
Match patient data → timeout (alt.)	420	498	Service time timeout na ścieżce alternatywnej
Receive sample state → timeout	232	292	Ścieżka alternatywna overnight
Match patient data → Wait for plate validation	162	5444	≈ service time WFPV (165 min) — PCR processing
Wait for plate validation → Receive sample state	~0	5921	Sekwencyjne, natychmiastowe

Kluczowy wniosek: **bottleneck to fizyczny czas procesowania PCR (~165 min)**, a nie czas oczekiwania między aktywnościami. System już korzysta z równoległości — wszystkie kroki inicjalizacji startują jednocześnie. Jedyna droga optymalizacji to zmniejszenie rozmiaru partii płytek (mniejsza partia = krótszy czas do zakończenia).

4. Odkrywanie modelu procesu

4.1 Alpha Miner (kontrprzykład)




Właściwość	Wartość
Miejsca	15
Przejścia	8
Łuki	41

Alpha Miner generuje uproszczoną sieć z 8 widzialnymi przejściami odpowiadającymi 8 aktywnościom. Model jest **zbyt prosty**: nie radzi sobie z pętlami (timeout powtarza się w procesie), nie modeluje prawidłowo skip'ów i alternatywnych ścieżek. Wynik conformance (fitness=0.51) potwierdza, że model nie opisuje rzeczywistego zachowania systemu.

Dlaczego Alpha Miner nie nadaje się do danych rzeczywistych? Algorytm zakłada acykliczny, skończony język. Pętle i zachowanie niedeterministyczne powodują brakujące miejsca w sieci Petriego (sieć nie jest sound), co uniemożliwia prawidłowe replay śladów.


4.2 Inductive Miner (IM)



Właściwość	Wartość
Miejsca	21
Przejścia	28
Łuki	64

IM rekurencyjnie dzieli log na podlogi i buduje **gwarancyjnie sound** model (każdy ślad logu może być odtworzony na modelu). Wynikowa sieć ma 28 przejść — wiele z nich to przejścia τ (ciche), modelujące pomijalne kroki. Fitness = 1.000 (idealna), ale bardzo niska precision (0.41) oznacza, że model jest zbyt ogólny — pozwala na wiele zachowań, których nie ma w logu.


4.3 Inductive Miner Infrequent (IMf, noise_threshold = 0.2)



Właściwość	Wartość
Miejsca	12
Przejścia	11
Łuki	26

IMf najpierw filtruje rzadkie zachowania (poniżej 20% częstości), a następnie stosuje algorytm Inductive Miner na oczyszczonym logu. Wynikowy model jest **znacznie prostszy**: 11 przejść wobec 28 w IM. Fitness spada do 0.96 (4.1% śladów nie przechodzi), ale precision wzrasta do 0.70. F1 = 0.806 — najlepszy wynik po HM.

4.4 Heuristic Miner (dep_threshold = 0.5)




Właściwość	Wartość
Miejsca	20
Przejścia	30
Łuki	69

Heuristic Miner buduje model na podstawie DFG z progami zależności (`dependency_threshold = 0.5` : łuk $A \rightarrow B$ uwzględniany gdy $(A \rightarrow B - B \rightarrow A) / (A \rightarrow B + B \rightarrow A + 1) \geq 0.5$). Wynik: **najwyższy F1 = 0.967** (fitness=0.975, precision=0.959). Model wiernie odwzorowuje obserwowane zachowanie, jednocześnie nie będąc zbyt restrykcyjny.

5. Analiza zgodności (Conformance Checking)

Conformance checking przeprowadzono metodą **token-based replay** (TBR): dla każdego śladu logu symulujemy wykonanie na sieci Petriego i zliczamy brakujące/nadmiarowe tokeny.

5.1 Tabela porównawcza



Algorytm	Fitness	% pasujących tras	Precision	F1	Miejsca	Przejścia
Alpha Miner	0.506	0.8%	1.000	0.672	15	8
Inductive Miner (IM)	1.000	100.0%	0.409	0.581	21	28
IMf (noise=0.2)	0.960	88.9%	0.695	0.806	12	11
Heuristic Miner	0.975	73.1%	0.959	0.967	20	30

5.2 Interpretacja

Alpha Miner — fitness 0.506 oznacza, że połowa śladów wymaga "dostrzeżenia" brakujących tokenów podczas replay. Precision wynosi 1.0, bo model jest tak restrykcyjny, że nie pozwala niemal na nic. W praktyce: model jest niepoprawny (niespójny z danymi), nie nadaje się do użycia produkcyjnego.

Inductive Miner (IM) — idealna fitness (100% tras przechodzi), ale precision 0.41. Model jest zbyt liberalny — dopuszcza sekwencje aktywności, których nigdy nie obserwowano w


danych. Nadaje się do weryfikacji formalnej poprawności, ale nie do opisu rzeczywistego procesu.

IMf — dobry kompromis: 88.9% tras pasuje, precision 0.70, F1 0.806. Uproszczony model (11 przejść) dobrze opisuje „normalne” zachowanie, ignorując rzadkie warianty (<20%).

Heuristic Miner — najlepszy model dla tych danych (F1=0.967). Wiernie odwzorowuje rzeczywiste DFG, nie generalizuje nadmiernie. 73.1% śladów przechodzi token replay w pełni — pozostałe 26.9% to ślady z nieoczekiwaną kolejnością aktywności (rare variants), które Heuristic Miner modeluje jako alternatywne ścieżki.

Wniosek: do analizy tego procesu Heuristic Miner jest najbardziej odpowiedni — log jest stosunkowo mało zaszumiony (47 wariantów, 65% przypadków na jednej ścieżce), co czyni go dobrym kandydatem dla algorytmu opartego bezpośrednio na DFG.

6. Model BPMN i propozycje usprawnień



Model BPMN wygenerowano z najlepszego modelu (Heuristic Miner, F1=0.967) przez konwersję Petri net → BPMN w pm4py. Kluczowe elementy:

Główna ścieżka (65% przypadków): Start → Match patient data → Wait for plate validation → Receive sample state → Callback timeout → timeout → End

Ścieżki z eksportem (~35% przypadków): Po Receive sample state możliwe gałęzie: - Export result → Export to EMS → Callback timeout - Export to EMS → Export result → Callback timeout - Export result → Callback timeout (bez EMS) - Export to EMS → Callback timeout (bez result)

Ścieżka z powiadomieniem: timeout → Send notification → (Wait for plate validation | Export to EMS | ...)

Propozycje usprawnień


- Optymalizacja Wait for plate validation (~162 min mediany na ścieżce głównej)** Główny bottleneck na ścieżce przetwarzania 88% przypadków. Płytki (wellplate) jest wypełniana próbkami, a walidacja następuje po zebraniu pełnej partii. Redukcja rozmiaru partii lub zwiększenie częstości uruchamiania procesu walidacji mogłaby skrócić ten czas o 30-50%.
- Równoległe wykonanie eksportów (AND-split)** Export result, Export to EMS i Send notification są w danych wykonywane sekwencyjnie, ale logicznie mogą być równoległe

(brak zależności danych między nimi). AND-split po `Receive sample state` skróciłby czas zakończenia przypadku o ~20–30 min dla 35% próbek.

3. **SLA dla przypadków przekraczających 8 godzin** P95 czasu trwania wynosi ~19 godzin. Przypadki ze ścieżką alternatywną (Match patient data → timeout, mediana 420 min) są prawdopodobnie wstrzymane przez brak dostępnej płytki lub błąd systemu. Alert lub mechanizm priorytetu po przekroczeniu 8 godzin zmniejszyłby liczbę takich przypadków.
4. **Optymalizacja konfiguracji timeout CPEE** Aktywność `timeout` to mechanizm kolejkowania silnika CPEE — pojawia się na wszystkich ścieżkach jako ostatnia aktywność. Optymalizacja interwałów `timeout`'a może skrócić oczekiwanie w kolejce bez zmiany logiki procesowej.
5. **Dedykowana ścieżka dla próbek pilnych** Dane nie zawierają priorytetu próbek. Wprowadzenie atrybutu `priority` pozwoliłoby kierować próbki pilne na ścieżkę pomijającą `Wait for plate validation` (np. do mniejszej płytki testowej lub natychmiastowego procesowania).

7. Odkrycie reguł decyzyjnych

7.1 Predykcja wyniku PCR




Cechy: `duration_min`, `n_events`, `hour`, `dayofweek` **Cel:** POSITIVE / NEGATIVE

Metryka	Wartość
Baseline (klasa wiodąca)	0.528
CV Accuracy (5-fold)	0.526 ± 0.009

CV accuracy niemal równe baseline (52.8%) — **wynik PCR jest niemożliwy do predykcji z cech procesowych**. Potwierdza to findings z Milestone 1: czas trwania, liczba zdarzeń,

pora dnia i dzień tygodnia są niezależne od wyniku badania. Wynik PCR zależy od biologii próbki, a nie od charakterystyki procesu laboratoryjnego.

7.2 Predykcja obecności eksportu



Cechy: duration_min, n_events, hour, dayofweek, pcr_binary **Cel:** czy przypadek zawiera aktywność eksportu (Export result / Export to EMS)

Target	Prevalence	Baseline	CV Accuracy	Top cecha
is_main_variant	65.0%	0.650	~0.65	duration_min
has_export	35.0%	0.650	0.999	n_events
has_notification	~20.0%	0.800	~0.98	n_events

Kluczowy wniosek: n_events niemal idealnie determinuje czy przypadek ma aktywność eksportu (CV=0.999). Reguła jest prosta i deterministyczna:


```
if n_events >= 7:
    → case zawiera eksport (Export result / Export to EMS)
else:
    → case bez eksportu (główna ścieżka, 5 zdarzeń)
```

Liczba zdarzeń wynika bezpośrednio ze struktury wariantu: główna ścieżka ma 5 aktywności (complete), ścieżki z eksportem mają 6-8. Nie jest to reguła „decyzyjna” w sensie biznesowym — to tautologia wynikająca z definicji wariantu. Rzeczywistym pytaniem jest: **co determinuje skierowanie próbki do ścieżki z eksportem?** Dane procesowe nie zawierają tej informacji — decyzja prawdopodobnie pochodzi z zewnętrznego systemu LIS lub protokołu laboratorium.

8. Analiza zasobów — endpointy jako proxy usług

Uwaga metodyczna: Log PCR Lab nie zawiera identyfikatorów zasobów (pracowników ani maszyn). Używamy **endpointów URL** jako reprezentacji mikrousług CPEE — jest to uzasadnione, ponieważ każdy endpoint odpowiada konkretnej usłudze laboratoryjnej obsługiwanej przez silnik procesowy. Analiza pokazuje obciążenie poszczególnych serwisów i wzorce przekazywania pracy między nimi.

8.1 Obciążenie endpointów




Po normalizacji (collapse per-instance IDs silnika CPEE) uzyskano **8 unikalnych logicznych endpointów**:

Endpoint (skrót)	Wywołania	Dominujące aktywności
mygreschner.com//backend/corr	~23 000	Match patient data, Receive sample state, Export result, ... (12 aktywności)
*/services/timeout	~15 000	timeout, Callback timeout
GET:cpee.org/.../receive	~7 000	Wait for plate validation
*/notifyall	~2 500	Send notification
*/pcheck	~2 000	Check for unfinished Plates
POST:cpee.org/.../send	~1 500	Notify per wellplate subprocess
cpee.org/flow/start/url	~400	Spawn per sample flow
cpee.org/engine/{id}/...	~200	Abandon/Stop spawned sample

`*/backend/corr` dominuje — obsługuje ponad 40% wszystkich wywołań i 12 różnych aktywności. To centralna usługa korelacji CPEE, hub systemu.

8.2 Macierz handover of work




Macierz przedstawia liczbę przekazania pracy między endpointami (ile razy endpoint B bezpośrednio następuje po endpointzie A w ramach tego samego przypadku). Kluczowe obserwacje:

- `*/backend/corr` → `*/timeout` : największy przepływ — po korelacji przypadek przechodzi do timeoutu (oczekiwanie na kolejny krok).
- `*/timeout` → `*/backend/corr` : powrót z timeoutu do korelacji — pętla `timeout` ↔ `backend/corr` to rdzeń procesu.
- `GET:cpee.org/.../receive` → `*/backend/corr` : po odebraniu stanu płytki (Wait for plate validation → Receive sample state) następuje powrót do korelacji.
- `*/notifyall` i `*/pcheck` są endpointami liściowymi — mało przekazanych.

8.3 Sieć współpracy endpointów


Sieć współpracy endpointów (przekazania > 30)



Sieć potwierdza centralną rolę `*/backend/corr` — łączy się z niemal wszystkimi innymi endpointami. Serwisy timeout tworzą wyraźną pętlę z korelatorem. Serwisy notyfikacji i sprawdzania płytek (`*/notifyall` , `*/pcheck`) to peryferyjne węzły z małą liczbą połączeń.

9. Analiza wąskich gardeł i symulacja Monte Carlo

9.1 Wąskie gardła




Przejście	Mediana [min]	n	Ocena
Match patient data → timeout (alt.)	420	498	⚠ Krytyczne
Receive sample state → timeout (alt.)	232	292	⚠ Krytyczne
Match patient data → Wait for plate validation	162	5 444	⚠ Krytyczne (główna ścieżka)
Send notification → Export to EMS	285	55	Wysokie
Export to EMS → timeout	194	39	Wysokie

Najistotniejszy bottleneck to **service time Wait for plate validation** (~165 min, n=5 444). Jak pokazała analiza struktury procesu (sekcja 3.2), **Match patient data** i **Wait for plate validation** startują jednocześnie — wartość 162 min na krawędzi DFG to service time PCR, nie czas oczekiwania w kolejce. To ograniczenie fizyczne (batchowy charakter procesu PCR), możliwe do zredukowania przez zmniejszenie rozmiaru partii.

Przejścia **→ timeout (alt.)** o ekstremalnych medianach (420, 232 min) to przypadki z ścieżki alternatywnej — próbki, które po wstępnym przetworzeniu trafiają bezpośrednio do kolejki timeout zamiast do Wait for plate validation. Prawdopodobna przyczyna: brak dostępnej płytki w momencie przetwarzania, skutkujący oczekiwaniem overnight.

9.2 Symulacja Monte Carlo



Metodologia: 2 000 przebiegów. Dla każdego przebiegu: losowy wariant z rozkładu empirycznego, dla każdego przejścia czas z empirycznego rozkładu (sampling bez zastępowania z obserwacji historycznych).

Metryka	Symulacja	Rzeczywiste
Mediana [min]	174.9	175.3
Średnia [min]	336.1	331.0
P95 [min]	1 228.4	1 148.5

Symulacja odtwarza medianę niemal idealnie (174.9 vs 175.3 min, błąd **0.2%**) i dobrze przybliża średnią (336.1 vs 331.0 min). Rozkład jest prawostronnie skośny — większość przypadków kończy się w 100–300 min, ale długi ogon (overnight) przesunął średnią do ~330 min.

Symulacja nieznacznie **przeszacowuje** P95 (1 228 vs 1 149 min, +7%) — empiryczne samplowanie czasów przejść z długim ogonem (zdarzenia overnight) generuje w 2 000 przebiegach nieco więcej ekstremów niż w rzeczywistym logu. Model dobrze odwzorowuje tendencję centralną i jest użyteczny do planowania przepustowości; dla pojedynczych ekstremów obarczony jest wariancją Monte Carlo (brak ustalonego ziarna — wartości mogą się różnić między przebiegami).

Scenariusz optymalizacyjny: Redukcja czasu Match patient data → Wait for plate validation z 162 do 60 minut (przez zmniejszenie partii płytek o 60%) przesunęłaby medianę czasu trwania z 175 do ~75 minut — skrócenie o 57%.

10. Mini Dashboard

Dashboard HTML dostępny w pliku <results/m3/dashboard.html>.

6 interaktywnych paneli: 1. Top 15 przejść DFG (częstość) 2. Rozkład czasu trwania przypadku 3. Top 10 wariantów procesu 4. Obciążenie endpointów 5. Wąskie gardła (mediana czasu przejścia) 6. Conformance — Fitness / Precision / F1 dla 4 algorytmów

11. Interpretacja procesu i wnioski

Co model mówi o analizowanym systemie?

System PCR Lab to **batchowy proces laboratoryjny** zarządzany przez silnik procesowy CPEE. Każda próbka przechodzi przez standardową sekwencję kroków: identyfikacja pacjenta → oczekiwanie na kompletację płytki → odczyt wyniku PCR → opcjonalny eksport do systemów zewnętrznych → zamknięcie przypadku. System jest wysoce powtarzalny (65% przypadków na jednej ścieżce) i działa w przewidywalnym rytmie dobowym (Mo–Pt, 11:00–21:00).

Najczęstsze ścieżki procesu

Wariant	Udział	Ścieżka
Główna	65.0%	Match patient data → Wait for plate validation → Receive sample state → Callback timeout → timeout
Top 2	70.9%	j.w. + eksport (Export result / Export to EMS)
Top 10	92.8%	Wszystkie powyższe + warianty kolejności eksportów

Gdzie pojawiają się opóźnienia?

1. **Wait for plate validation** (~162 min) — oczekiwanie na skompletowanie płytki 96-studzienkowej. To ograniczenie technologiczne procesu PCR, ale redukowalne przez zmniejszenie rozmiaru wsadu.
2. **Ścieżka alternatywna (brak płytki)** — 498 przypadków z przejściem Match patient data → timeout (mediana 420 min). Próbkę bez przypisanej płytki czekają na kolejny cykl pracy laboratorium, często overnight.
3. **Sekwencyjne eksporty** — w 35% przypadków aktywności Export result / Export to EMS / Send notification są wykonywane sekwencyjnie, choć mogłyby być równoległe.

Rekomendacje biznesowe

Rekomendacja	Wpływ	Trudność
Zmniejszenie rozmiaru partii płytek (96 → 48)	–50% mediany czasu na głównej ścieżce	Średnia
Równoległość eksportów (AND-split)	–20–30 min na 35% przypadków	Niska
SLA 8h + alert dla wstrzymanych próbek	Eliminacja outlierów overnight	Niska
Priorytetyzacja próbek pilnych	Skrócenie P95	Wysoka
Optymalizacja timeout CPEE	Redukcja overhead kolejkwania	Niska

Ograniczenia analizy

- **Brak zasobów w logu:** analiza endpointów zamiast pracowników / urzędzeń — nie można ocenić obciążenia personelu.
- **Brak atrybutu priorytetu próbki:** niemożna odróżnić próbek rutynowych od pilnych.
- **Zewnętrzny kontekst nieznany:** decyzja o skierowaniu na ścieżkę z eksportem pochodzi z zewnętrznego systemu LIS, nieprzedstawionego w logu. Drzewo decyzyjne (`n_events` jako determinant) ujawnia tautologię, nie przyczynę.
- **Dane z jednego okresu** (kwiecień–czerwiec 2023): wzorce mogą różnić się w szczycie pandemii od normalnej pracy laboratorium.