

Milestone 1

Autorzy: Mateusz Świątek, Maciej Mężyk, Patryk Skowron
Zbiór: PCR Lab Data
Źródło: [Zenodo #11617408](#)
Okres: kwiecień–czerwiec 2023
Notebook: [notebooks/01_m1_eda.ipynb](#)

1. Opis zbioru danych i kontekst

Dane pochodzą z systemu CPEE (Cloud Process Execution Engine), który automatyzuje laboratorium PCR. Każda próbka biologiczna przechodzi kilka kroków: rejestracja, dopasowanie danych pacjenta, oczekiwanie na płytkę, odczyt wyniku. System loguje każdy krok z czasem rozpoczęcia i zakończenia.

Jeden przebieg próbki = **case**. Jeden krok = **zdarzenie (event)**.

Surowy log: 6 339 case'ów, 317 905 zdarzeń. Ponad połowa to zdarzenia techniczne systemu. Po filtracji zostaje **134 099 zdarzeń biznesowych**.

Typy procesów

Proces	Co to	Ile case'ów	Zdarzeń na case
Sample	Jedna próbka od rejestracji do wyniku	6 166	10–12
Wellplate	Zarządzanie jedną płytką (zbieranie próbek, PCR)	167	64 – 31 838
Lab Plain Instance	Cykl pracy laboratorium	4	330 – 7 983
Lab Finish Watcher	Zamykanie płytek	2	~580

Dalej analizujemy tylko **Sample** — to właściwy proces diagnostyczny. Wellplate jest pomocniczy (grupuje próbki na płytkę przed PCR).

2. Atrybuty logu zdarzeń

Kolumna	Znaczenie	Status
<code>instance_uuid</code>	ID case'a	kompletny
<code>activity</code>	Nazwa kroku (np. "Match patient data")	8 unikalnych
<code>timestamp</code>	Czas zdarzenia (UTC)	kompletny
<code>lifecycle</code>	<code>start</code> / <code>complete</code>	kompletny
<code>pcr_result</code>	Wynik testu: POSITIVE / NEGATIVE	brak dla 5.6% próbek
<code>ct</code>	Cycle threshold (im niższy, tym więcej wirusa)	tylko POSITIVE

Kolumna	Znaczenie	Status
endpoint	Adres serwisu obsługującego krok	kompletny

Czego brakuje

- **Identyfikator osoby/urzędnika.** Kolumna **endpoint** zawiera adresy serwisów (np. **mygreshner.com/.../backend/corr**), ale nie mówi kto ani co fizycznie przetwarza próbkę. Analiza zasobów (resource) odpada.
- **Koszty / priorytety** — brak w logu.

3. Jakość danych

Kluczowe pola (ID, aktywność, timestamp, lifecycle) nie mają żadnych braków. Jedyny brak: 346 próbek (5.6%) bez wyniku PCR.

Duplikatów brak. Chronologia poprawna, żaden case nie ma zdarzeń w złej kolejności. Typy danych również w porządku.



Większość kroków ma pełne pary start/complete. Jedynie w **Send notification**, **Export to EMS**, **Export result** brakuje ~1–5% startów/completów.

4. Eksploracyjna analiza danych

4.1 Podstawowe statystyki

Metryka	Wartość
Próbki (cases)	6 166
Zdarzenia biznesowe	75 263
Unikalne aktywności	8
Mediana zdarzeń na próbkę	10
Mediana czasu przetwarzania	~3 h

4.2 Warianty procesu




W logu jest 122 warianty, ale większość próbek idzie tą samą drogą. Top 2 warianty = 52% próbek, top 10 = 79%.

Główna ścieżka (~65% próbek):

Krok	Co robi
timeout	Rejestracja próbki, start odliczania
Match patient data	Dopasowanie danych pacjenta
Wait for plate validation	Czekanie aż płytka się zapełni
Receive sample state	Odebranie wyniku PCR
Callback timeout	Zamknięcie procesu


Drugi wariant (23%) to ta sama ścieżka z zamienioną kolejnością timeout i Match patient data.

4.3 Czas trwania kroków



Prawie cały czas próbki to czekanie na płytkę: **wait for plate validation** (~165 min) i **timeout** (~175 min). Dopasowanie pacjenta, odbiór wyniku, zamknięcie zajmuje sekundy. Eksporty wyników zwykle ~5 min, ale rozrzut jest duży.


4.4 Rozkład zdarzeń i czasu na próbkę



Większość próbek ma dokładnie 10 zdarzeń (5 kroków z start + complete). Próbki z >12 mają dodatkowo eksporty/powiadomienia.


Czas: większość ok. 3h, ale widać ogon w prawo. Próbki >17h możliwe, że utknęły na noc (laboratorium wtedy nie pracuje).

4.5 Częstość kroków




5 głównych kroków występuje ~6000 razy, czyli raz na próbkę.

4.6 Wyniki PCR i Ct




53% NEGATIVE, 47% POSITIVE, 346 bez wyniku. Rozkład Ct dla próbek POSITIVE jest normalny, średnia ~26.

4.7 Heatmapa aktywności




Lab pracuje głównie Pon–Pt ok. 11–21, peak Pon–Wt 12–18. Soboty trochę aktywności, niedziele prawie pusto. Poniedziałkowy peak może być nadrabianiem po weekendzie.

4.8 Timeline




Początek kwietnia: >200 próbek dziennie. Koniec maja: ~50. Widać spadek i rytm tygodniowy (weekendy). Dane są z wiosny, spadek zapewne pokrywa się z wygaszeniem fali zakażeń.

4.9 Wpływ wyniku PCR na czas przetwarzania



Rozkłady czasu dla NEGATIVE i POSITIVE są prawie identyczne. POSITIVE minimalnie dłuższe (mediana ~183 vs ~172 min). Wynik PCR nie wpływa na czas.

4.10 Endpointy (serwisy)



Każdy krok ma przypisany endpoint (adres serwisu). Najczęstszy: mygreschner.com/.../backend/corr (11k wywołań). Endpointy mówią który serwis obsługuje krok, ale nic o osobach ani urządzeniach.

5. Wnioski

Dane są czyste — żadnych duplikatów, spójna chronologia, poprawne typy. Braki: 5.6% próbek bez wyniku PCR i brak identyfikatora osoby/urządzenia (resource).

Proces jest prosty — 65% próbek przechodzi identyczną ścieżkę 5 kroków. Reszta wariantów to albo zamieniona kolejność kroków równoległych, albo dodatkowe eksporty. Czas przetwarzania (~3h) to w zasadzie czekanie na płytkę — samo przetwarzanie trwa sekundy. To bottleneck procesu.

Wynik PCR (53% neg, 47% poz) nie wpływa ani na ścieżkę, ani na czas. Lab pracuje Pon–Pt 11–21, z peakiem na początku tygodnia. Liczba próbek spada przez cały okres (>200 → ~50/dzień), co pokrywa się ze spadkiem zakażeń wiosną 2023.